

Metaheuristike za selekciju atributa/karakteristika

Darija Eremija 122/2018

Ivan Dobrić 119/2018

Opis problema

- Veliki broj podataka, da li su svi korisni?
- Pretpostavimo da skup podataka S ima n atributa
- $S = \{f_1, f_2, \dots, f_n\}$
- Cilj je pronaći najbolje podskupove od S
- $D = \{f_1, f_2, \dots, f_m\}$, $m < n$
- Rešenje– Metaheuristički algoritmi

Genetski algoritam

- Reprezentacija jedinki:
- Kod – Niz binarnih vrednosti fiksne dužine
 - True - rešenje uključuje taj atribut
 - False – rešenje ne uključuje taj atribut
- Funkcija cilja:


$$\alpha \cdot ta\check{c}nost + (1 - \alpha) \cdot \left(1 - \frac{broj\ uklju\check{c}enih\ atributa}{ukupan\ broj\ atributa}\right)$$

Genetski algoritam

- Inicijalizacija:
 - Bez korišćenja heuristike
 - Sa korišćenjem heuristike (informativnost atributa)
- Selekcija
 - Turnirska selekcija
 - Ruletska selekcija
 - Rangovska selekcija
 - Nasumična selekcija
- Ukrštanje – jednopoziciono ukrštanje
- Mutacija - (podrazumevana ili adaptivna)
- Politika zamene generacija – generacijska
- Elitizam

NSGA II – Nedominirani genetski algoritam sortiranja

- Višekriterijumska optimizacija
- Moguće istovremeno direktno optimizovati više ciljnih funkcija
- Povratna vrednost – Pareto front



NSGA II – Nedominirani genetski algoritam sortiranja

- Funkcija dominacije:
- Jedinka dominira drugom individuum kada važe sledeća dva uslova:
- 1) Individua je bolja ili jednaka u oba cilja (veća ili jednaka tačnost i manji ili jednak procenat selektovanih atributa)
- 2) Individua je strogo bolja bar u jednom od ciljeva.
- Nedominirao sortiranje populacije:
Jedinke nad kojima nijedna jedinka ne dominira formiraju prvi front.
Jedinke kojima dominiraju samo jedinke iz prvog fronta čine drugi front
- ...
- Rastojanje gužve– meri raznolikost rešenja I obezbeđuje širinu pareto fronta

NSGA II – Nedominirani genetski algoritam sortiranja

- Opis rada algoritma:
- 1) Kreira se početna populacija nasumičnih jedinki
- 2) Računaju se funkcije cilja (tačnost klasifikacije i procenat selektovanih atributa) za svaku jedinku
- 3) Za svaku generaciju algoritam izvršava sledeće korake:
 - Sortiranje populacije u pareto frontove
 - Računanje rastojanja gužve u svim frontovima
 - Selekcija roditelja binarnom turnirskom selekcijom
 - Generisanje potomaka ukrštenjem i izabranom mutacijom
 - Evaluacija kombinovane populacije koju čine roditelji i deca
 - Opciono mutiranje duplikata
 - Formiranje nove populacije elitističkim izborom na osnovu fronta i rastojanja gužve
- Po završetku algoritma ispisuje se Pareto front.







Prošireno simulirano kaljenje

- Uveli smo parametar strpljenje koji predstavlja broj uzastopnih iteracija bez poboljšanja nakon kojih se algoritam prekida.
- U originalnoj verziji u svakoj iteraciji prolazi se kroz attribute fiksnim redosledom, a u proširenoj verziji se pre svake iteracije prvo nasumično mešaju indeksi kako bi se proširio prostor pretrage.
- Uveli smo vrstu hlađenja, ona može biti: linearna, eksponencijalna i logaritamska. Vrsta hlađenja se prosleđuje kao argument pri inicijalizaciji algoritma i ovim parametrom se kontroliše brzina opadanja temperature samim tim i verovatnoća prihvatanja lošijih rešenja.







BPSO

- Binarni PSO
- Umesto Euklidskog rastojanja koristi se modifikacija Hamingovog
- Brzina predstavlja verovatnoću da će se promeniti vrednost bita
- $F(x) = |x| / (1 + |x|)$ se koristi kao transfer funkcija da dobijemo verovatnoće
- Koristimo adaptivnu inerciju koja se menja kroz iteracije







Skup: "Ionosphere"



Skup: "Oral toxicity"



Skup: "Breast cancer"



Skup: "Ionosphere"

Ukupan broj atributa: 34, trening tačnost: 0.91, test tačnost: 0.92

Ionosphere	Broj izabranih atributa	Procenat izabranih atributa	Trening tačnost	Test tačnost
NSGA2	7	21%	0.94	0.89
SAE	5	15%	0.88	0.88
GA	2	6%	0.91	0.89
GA+SAE	2	6%	0.91	0.86
BPSO	7	21%	0.89	0.88
BPSO+SAE	6	18%	0.90	0.88

Skup: "Oral toxicity"

Ukupan broj atributa: 1024, trening tačnost: 0.93, test tačnost: 0.93

Oral toxicity	Broj izabranih atributa	Procenat izabranih atributa	Trening tačnost	Test tačnost
NSGA2	37	4%	0.92	0.91
SAE	459	45%	0.93	0.93
GA	312	30%	0.93	0.93
GA+SAE	305	30%	0.93	0.93
BPSO	450	44%	0.93	0.93
BPSO+SAE	417	41%	0.93	0.93

Skup: "Breast cancer"

Ukupan broj atributa: 30, trening tačnost: 0.96, test tačnost: 0.96

Breast cancer	Broj izabranih atributa	Procenat izabranih atributa	Trening tačnost	Test tačnost
NSGA2	3	10%	0.97	0.96
SAE	5	17%	0.93	0.95
GA	2	7%	0.95	0.93
GA+SAE	2	7%	0.95	0.93
BPSO	6	20%	0.95	0.96
BPSO+SAE	5	17%	0.95	0.95

Zaključak

- NSGA2 nudi više rešenja gde možemo da bираmo koji kompromis pravimo
- GA se pokazao bolje od BPSO
- SA često popravi već dobro rešenje
- SA pojedinačno uglavnom da nešto lošije rešenje od ostalih
- Svi algoritmi dosta zavise od broja inicijalno izabranih atributa

Preporuka za proširenje: podešavanje hiperparametara i kombinovanje algoritama